# Moderne Algorithmen für die Garbage Collection

Vorstellung moderner Algorithmen für die Garbage Collection am Beispiel von Go und Java

xnacly, hlxid

23. Mai 2024

**DHBW** 

- 1. Garbage collection
- 2. Strategien
- 3. Programmiersprachen
- 4. Implementierungen
- 5. Performance
- 6. Borrow Checking
- 7. Fragen?

# Garbage collection

#### **Garbage collection**

#### Garbage collection ist definiert als

- Erkennung von nicht mehr verwendeten Speicherbereichen
- automatisches Entfernen dieser

#### Und zielt darauf ab das obige:

- schnell
- effizient
- mit wenig Latenz
- mit wenig RAM und CPU Auslastung

umzusetzen.

#### Garbage collection - Nutzen

#### Befreit den Programmierer zumeist von:

- Manueller Speicherallokierung mit malloc, calloc und realloc
- Manueller Speicherfreigabe mit free
- Pointer arithmetik

#### Verhindert Fehler wie: 1

- Seg faults (illegaler Speicherzugriff)
- Use after free (Speicherzugriff auf bereits aufgeräumte Speicherbereiche)
- Memory leaks (Speicher wird nach Verwendung nicht freigegeben)

 $<sup>^170\%</sup>$  der CVE's von Chromium sind Speicherzugriffbezogen, siehe: https://www.chromium.org/Home/chromium-security/memory-safety/

#### Garbage collection - Problematiken

- Peformance schlechter im Vergleich zu manuellem management und borrow checker
- Einfluss von GC-zyklen auf Program nicht vorhersehbar
- Manuelle Allokationen mit Speicherarena effizienter für große Datenmengen als jedes Objekt einzeln allokieren

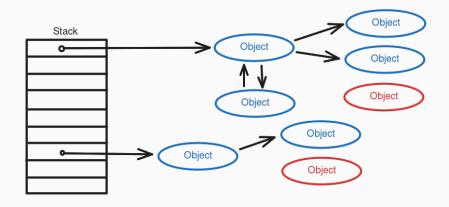
# Strategien

#### Strategien

Strategien unterscheiden sich in ihrer:

- Erkennung von unerreichbaren Objekten
- Entfernung von unerreichbaren Objekten
- Latenz, RAM und CPU Verbrauch

# Strategien - Mark & Sweep

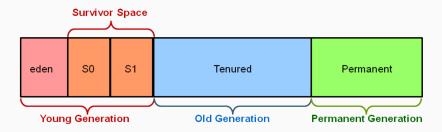


#### Strategien - Generational garbage collection

Optimierung basierend auf der Beobachtung, dass die meisten Objekte nur kurzlebig sind (Infant Mortality)

Aufteilung in drei Speicherbereiche aufgeteilt:

- Young, bestehend aus Eden und Survivor Space
- Old
- Permanent



# Strategien - Generational garbage collection

#### Eden

- Alle neuen Objekte werden hier allokiert
- Objekte welche einen GC Lauf überleben, werden in den Survivor Space verschoben

#### Survivor

- Hier sind Objekte welche eine gewisse Zeit überlebt haben
- Objekte welche eine längere Zeit überlebt haben werden in den Old Space verschoben

#### Old

 Hier sind Objekte welche schon länger existieren und es unwahrscheinlich ist, dass sie bald gelöscht werden

Eden wird aufgrund von Infant Mortality häufig collected, ist aber klein da lang lebende Objekte nicht dort sind.

### **Strategien - Reference counting**

- Jedes Objekt hat einen Zähler, welcher die Anzahl der Referenzen auf das Objekt zählt.
- Beim Erstellen eines Pointers auf das Objekt wird der Zähler inkrementiert, beim Löschen dekrementiert.
- Wird der Zähler 0, so wird das Objekt deallokiert.

Probleme bei Referenzzyklen: Zähler wird nie 0, Objekte werden nicht gelöscht.

# **Strategien - Reference counting**

```
struct PyObject {
    // ...
    uint32_t ob_ref_local;  // local reference count
   // ...
};
    Stack
```

11/23

# Programmiersprachen

# Programmiersprachen

- Viele Sprachen mit und ohne GC
- Algorithmen, Implementierungen und Performance sehr unterschiedlich
- High level sprachen eher mit GC, low level eher ohne

# Programmiersprachen - Ohne gc

- C
- manuelles memory managment
- C++
  - manuelles memory managment
  - reference counting on demand
- Rust
  - borrow checker
  - reference counting on demand

# Programmiersprachen - Mit gc

- Go
  - escape analysis
  - mark & sweep
  - Compiliert in Maschinen Code(AOT), GC in generierter Binary
- Java
  - mehrere garbage collectoren
  - generational standardmäßig
  - Compiliert in Bytecode(AOT), Ausführung mit Bytecode vm (JVM)
- Python
  - Reference counting
  - Erkennung von Referenzzyklen
- JavaScript
  - generational
  - JIT, Bytecode vm (V8)

Implementierungen

#### Implementierungen - Go

Go verwendet einen Mark & Sweep garbage collector.

- Concurrent
- Tri-color (objekte werden eingefärbt)
- Minimale Latenz durch kurzes stop the world <sup>2</sup>
- Konfigurierbar über:
  - GOGC: Größe heap relativ zur Größe aller erreichbaren Objekte

<sup>&</sup>lt;sup>2</sup>siehe: https://www.youtube.com/watch?v=aiv1JOfMjm0

#### GO - Tri-color

# Basierend auf Dijkstra (1978)<sup>3</sup>

- Objekte: Weiß, Grau oder Schwarz
- zu Begin des GC-Zyklus alle Objekte Weiß
- GC besucht alle Roots<sup>4</sup> markiert als Grau
- Ein Objekt wird ausgewählt und als Schwarz markiert, GC sucht ab hier nach Referenzen zu anderen Objekten
- ullet Wird ein weißes Objekt gefunden o als grau markiert.
- Prozess wird wiederholt bis keine weißen Objekte mehr
- Verbleibende weiße Objekte sind nicht erreichtbar ⇒ Deallokieren

<sup>&</sup>lt;sup>3</sup>siehe: https://dl.acm.org/doi/10.1145/359642.359655

<sup>&</sup>lt;sup>4</sup>stack & statische variablen, etc...

#### Implementierungen - Java

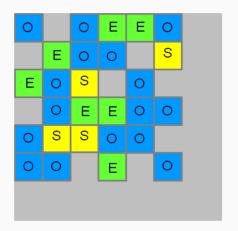
Bei Java gibt es verschiedene GC-Implementierungen, welche via CLI Flag ausgewählt werden können.

- Serial GC
- Parallel GC
- Concurrent Mark and Sweep (CMS)
- Garbage First (G1) GC
- Z GC

G1 ist Standard und wird deshalb hier vorgestellt.

#### Java - G1 GC Speicherstruktur

G1 ist ein generational GC. G1 allokiert Speicherblöcke, welche jeweils einer Generation zugeordnet sind.



E Eden Space
S Survivor Space
Old Generation

#### Java - G1 GC Funktionsweise

- Wird eine Generation zu voll, so wird Garbage Collection gezielt für eine/mehrere Speicherregionen der Generation ausgeführt.
- Überlebende Objekte werden in einen neuen Bereich der gleichen oder darüberliegenden Generation kopiert
  - ⇒ Kompaktierung
- Dannach ist die Region leer und kann neu allokiert werden.

# Performance

#### **Performance**

Diverse Kriterien möglich, hier beschränkt auf:

- Speicherverbrauch: stärke RAM-Intensivität
- Latenz: Umfang Stoppzeiten des Programs
- Sicherheit: Speicherzugriffsicherheit
- Nutzbarkeit: Komplexität der Strategien

# Borrow Checking

#### **Borrow Checking - Theorie**

free Calls können automatisch eingefügt werden, wenn der Compiler weiß wielange ein Objekt verwendet wird (*Lifetime*) ⇒ automatisches Speichermanagement ohne GC Um dies möglich zu machen werden die Konzepte des *Ownership* und *Borrowing* eingeführt.

# Borrow Checking - Ownership & Borrowing

#### Ownership:

- Eine Variable hat einen Owner in Form einer Funktion
- Ownership kann von einer Funktion an eine andere übergeben werden (pass by value/return via moves)

Um auf Variablen an mehreren Stellen zugreifen zu können, kann diese geborrowed (verliehen) werden:

- Der Owner einer Variable kann diese an andere Strukturen verleihen.
- Borrowing ist nur für einen bestimmten Zeitraum möglich (Lifetime)
- Borrows dürfen nicht über die Lifetime des Owners hinaus bestehen, sichergestellt durch den Borrow Checker

### Borrow Checking - Beispiel in Rust

```
use std::io::stdin;
fn main() {
    println!("Eingabe: ");
    let line = stdin().lines().next();
    if let Some(line) = line {
        let line = line.expect("Fehler beim Lesen");
        println!("Gelesene Eingabe: \"{line}\"");
    } else {
        println!("Keine Eingabe");
```

# Fragen?